



DATUMO

Cecha (nie)pospolita

2026



Cecha pospolita a Cecha własna

`txn_count_7d`

Liczba transakcji z ostatnich 7 dni

Okno czasowe

Late events

Źródło danych

Definicja oznaczeń

Paszport cechy

NAZWA	txn_count_7d
DEFINICJA	Liczba zaakceptowanych transakcji użytkownika
OKNO	[t-7d, t) — przedział otwarty z prawej
PUNKT ODCIĘCIA	event_time, nie data załadowania
ŹRÓDŁO	bq://.../transactions_raw
ŚWIEŻOŚĆ	Sync co godzinę, dopuszczalne opóźnienie 90 minut
WŁAŚCICIEL	Zespół Risk



Jeśli ktoś w Waszej organizacji umie wypełnić ten formularz dla dowolnej cechy – macie warstwę semantyczną. Jeśli nie – macie tabelę.

Co wyniesiesz z **tej sesji?**



**Wzorzec point-in-time
do wdrożenia od jutra**



Manifest wydania



**Granica
odpowiedzialności
Feature Store**



Pięć pytań do zespołu



**Cztery poziomy
monitoringu i kto je czyta**



**Kiedy Feature Store
się nie opłaca**

Pięć problemów jednej kolumny

Ta sama cecha zwraca dwie różne liczby

Trening widzi przyszłość

Hurtownia nie odpowie w dziesięć milisekund

Nikt nie wie, skąd ta cecha pochodzi

Każdy model buduje cechy od zera

Cztery rozwiązuje Feature Store. Jednego nie rozwiąże żadne narzędzie.

Ta sama cecha, dwie liczby


14

ścieżka treningowa

4

produkcja

Okno w treningu — liczone po dacie



Okno na produkcji — do sekundy decyzji

- ✓ ten sam użytkownik, ta sama sekunda
- ✓ model uczy się czternastek a dostaje czwórki

0,924 AUC

Walidacja

0,714 AUC

Produkcja

0

**Zmian w kodzie
modelu**

Ten sam kod. Ten sam artefakt. Nikt nie zmienił algorytmu.
Błąd był w jednej kolumnie.

Ile to kosztuje?

Koszt bezpośredni

O ile wzrosła kolejka ręcznej weryfikacji. Ile przeszło niewykrytych.

Koszt czasu

Ile tygodni zespół szukał błędu w modelu, bo tam szuka się najwygodniej.

Koszt zaufania

Czy biznes jeszcze raz podpisze się pod wdrożeniem modelu.



Trzeci jest najdroższy
i nie występuje w żadnym budżecie

Hurtownia nie odpowie w dziesięć milisekund

BigQuery

Warstwa Online

• sekundy i nigdy nie miało być inaczej

• dziesiątki milisekund



To nie jest kwestia optymalizacji zapytania.

To dwie różne warstwy o dwóch różnych zadaniach.

Bez warstwy serwowania model online po prostu nie powstaje.



DEMO

To był SQL. Po co więc Feature Store?

Poprawność point-in-time policzył BigQuery. Feature Store nie liczy jej za Was

Warstwa online synchronizuje się z tego samego BigQuery. Jedna definicja, dwa odczyty. Sync jest techniczny, nie semantyczny.

Feature Store nie liczy point-in-time. Wymusza strukturę, w której point-in-time jest jednym zapytaniem: encja, znacznik czasu, historia, właściciel, harmonogram.



Poprawna wersja jest krótsza od błędnej

Wyliczenie cech

```
SELECT
  txn_id,
  user_id,
  event_time,
  COUNT(*) OVER (
    PARTITION BY user_id
    ORDER BY UNIX_SECONDS(event_time)
    RANGE BETWEEN 604800 PRECEDING AND 1 PRECEDING
  ) AS txn_count_7d

FROM `fraud_raw.transactions`
```



Błąd polegał na tym, że ktoś dołożył konwersję na datę żeby zapytanie było czytelniejsze. Poprawka nie dodaje złożoności. Usuwa ją.

Join uwzględniający stan cech

```
# Wzorzec point-in-time
SELECT s.txn_id, s.decision_time, s.label, r.amount, f.txn_count_7d...

FROM `fraud_training.fraud_labels` AS s
JOIN `fraud_raw.transactions` AS r
  ON r.txn_id = s.txn_id
JOIN `fraud_features.feature_values` AS f
  ON f.entity_id = s.entity_id

-- migawka NIE PÓŹNIEJSZA niż decyzja i nie starsza niż TTL
AND f.feature_timestamp <= s.decision_time
AND f.feature_timestamp >  TIMESTAMP_SUB(s.decision_time, INTERVAL 10 DAY)

-- z pasujących migawek: najświeższa
QUALIFY ROW_NUMBER() OVER (
  PARTITION BY s.txn_id ORDER BY f.feature_timestamp DESC) = 1
```

Co Feature Store właśnie zrobił

Jedna definicja

jedno źródło, dwa odczyty

Świeżość

Sync co godzinę, zadeklarowane opóźnienie, widoczny ostatni sync

11 ms

Zamiast 8 sekund

Rejestr

Właściciel, źródło, harmonogram, ostatnia synchronizacja



Cztery mechanizmy które widzieliście. Trzy problemy z pięciu


Nikt nie wie, skąd ta cecha




- Pytanie, które pada podczas incydentu: kto jest właścicielem tej zmiennej?
- Odpowiedź, która pada najczęściej: musielibyśmy sprawdzić.
- Rejestr cech odpowiada bez sprawdzania: źródło, harmonogram, ostatni sync, właściciel, rozkład względem zeszłego tygodnia
- To warstwa, w której sygnał o problemie pojawia się **godziny** przed metryką jakości modelu.

Każdy model buduje cechy od zera

Bez wspólnej warstwy — 4 × praca, 4 × definicja



Ze wspólną warstwą — 1 × praca, 1 × definicja



Pierwszy model płaci pełny koszt zbudowania cechy.

Drugi, trzeci i czwarty dostają ją za darmo.

To jedyna z tych zalet, która skaluje się ekonomicznie. Musicie wierzyć na słowo

Co właściwie wdrażasz?



Model

Wagi i preprocessing



Definicje cech

Wersja feature view



Konfiguracja

Progi, mapowania



Kontrakt

Schemat ządania

A background image of a city skyline, likely Dubai, with several skyscrapers including the Burj Khalifa, partially obscured by a thick layer of white fog or low clouds. The sky is a pale blue.

Zepsuty kod zwraca błąd.
Zepsuty model zwraca liczbę.

- **Monitoring**
- **Decyzje**
- **Dojrzałość operacyjna w systemach ML**

Cztery poziomy degradacji

Dane wejściowe

Rozkłady, braki, świeżość

minuty

Cechy

Rozjazd i dryf rozkładu

godziny

Predykcje

Dryf outputu

dni

Wynik biznesowy

Skuteczność vs etykiety

tygodnie

Jedyny poziom, który interesuje biznes, jest jedynym, którego nie da się zmierzyć na czas.

Od alertu do decyzji

**Zmieniły się dane, świat
ten sam**

Napraw dane : inżynier | godziny

**Zmienił się świat,
zależności te same**

Doucz model: ML engineer | dni

**Zmieniła się sama
zależność**

Przebuduj: zespół | tygodnie

**Skutek biznesowy
przekracza próg**

Wycofaj: biznes | minuty



Wycofanie modelu to decyzja biznesowa

Gdzie jesteście?

Cechy liczone w notebookach, wdrożenie to
przepisanie kodu do serwisu

0

Cechy w repozytorium i pipeline, ale trening i
serwowanie to dwie implementacje

1

Jedna definicja, warstwa serwowania, manifest
wydania, rollback całej paczki

2

Monitoring czterech poziomów z programami i
właścicielami

3

Granica, która ma znaczenie zawsze, przebiega między zerem a jedynką.

Czego Feature Store nie rozwiązuje

Nie sprawdza poprawności definicji

Z radością zsynchronizuje błędne okno czasowe

Nie poprawia jakości danych wejściowych

Błędne dane wejdą i wyjdą, tylko szybciej

Nie zdefiniuje semantyki biznesowej

“Aktywny klient” to nadal decyzja człowieka

Nie zwalnia z myślenia o momencie, w którym dana powstaje



Feature Store nie pisze umowy. Egzekwuje ją

Kiedy Feature Store się **nie opłaca?**

Warstwa online kosztuje niezależnie od ruchu

Bigtable przy jednym węźle to około 0,65 USD za godzinę, czyli rzędu 470 USD miesięcznie. Model uruchamiany raz na kwartał tego nie odpracuje.

Predykcja wsadowa nie potrzebuje warstwy online

Trenujecie i serwujecie w BigQuery ML? Poprawność point-in-time macie natywnie, jedną funkcję SQL

Zespół nie ustalił jeszcze definicji

Narzędzie utrwali chaos zamiast go uporządkować


A jeśli się opłaca, pierwszy krok to nie jest Feature Store. To cztery do sześciu tygodni pracy nad definicjami, w SQL, na infrastrukturze, którą już macie.

Feature Store to dyscyplina



- Feature Store wymusza konkretne podejście. Cecha przestaje być kodem w czyimś notebooku. Zaczyna mieć właściciela, wersję, kontrakt i historię
- Zmiana definicji jest wydarzeniem, nie commitem. Ma wersję, ma właściciela, wchodzi do tej samej paczki co model
- To jest ten sam ruch, który zrobiliście z kodem dziesięć lat temu. Dziś robicie go z danymi, które wchodzi do modelu.

Zabierzcie to ze sobą



5

pytań na jutro



Czy potrafimy wskazać jedno miejsce, w którym zdefiniowana jest nasza najważniejsza cecha?



Czy trening i produkcja czytają ją z tego samego źródła?



Czy potrafimy odtworzyć jedną konkretną decyzję sprzed trzech miesięcy - i ile to zajmie?



Co dokładnie cofa nasz rollback: model czy całą paczkę?



Kto dostaje alert o dryfie, jaką ma procedurę i kiedy ostatnio z niej skorzystał?



Q&A

Dziękuję za uwagę!

Chcesz wiedzieć więcej? Zapraszam do kontaktu ze mną!



Rafał Jankowski
Senior Data Engineer



+48 536 171 454



rafal.jankowski@datumo.pl



[rafal-jankowski](https://www.linkedin.com/in/rafal-jankowski)



Michał Lutyński
Senior Data Engineer



+48 501 405 483



michal.lutynski@datumo.pl



[michal-lutynski](https://www.linkedin.com/in/michal-lutynski)



www.datumo.io



[datumo-pl](https://www.datumo-pl.com)